

Expressions Régulières

1. Introduction aux Expressions Régulières

Définition

- Les **expressions régulières (ER)** sont des descriptions symboliques utilisées pour définir des motifs de caractères.
- Utilisées dans les outils Linux (`grep`, `sed`, `awk`, etc.) et des langages comme Perl, elles servent pour rechercher ou manipuler des chaînes de caractères.

Différences avec la génération de noms

- Les ER sont **plus puissantes** que le mécanisme de génération de noms de fichiers, qui est limité aux caractères génériques (*, ?, []).

Utilisations courantes

- Rechercher des motifs spécifiques dans des fichiers.
 - Valider des formats (emails, numéros de téléphone, etc.).
 - Remplacer du texte dans des fichiers.
-

2. Conventions des ER

Deux types principaux

1. **Expressions Régulières de Base (BRE)** : Syntaxe limitée, utilisée dans des outils comme `grep` standard.
2. **Expressions Régulières Étendues (ERE)** : Syntaxe avancée, requiert souvent l'option `-E` pour `grep`.

Caractères spéciaux

- Ces caractères doivent être échappés (\) pour être utilisés littéralement :
 - | . * + ? ^ \$ () [] { } \
-

3. Expressions Régulières Atomiques (ERA)

Définition

- Les ERA sont les **éléments de base** pour construire des ER. Elles définissent des **ensembles de caractères**.

Principaux motifs d'ERA

Motif	Signification	Exemple
<code>ch</code>	Correspond exactement au caractère <code>ch</code>	<code>a</code> correspond à "a".
<code>.</code>	Correspond à tout caractère	<code>a.b</code> correspond à "acb".
<code>[a-z]</code>	Tout caractère entre <code>a</code> et <code>z</code>	<code>[a-c]</code> correspond à "a", "b".
<code>[^a-z]</code>	Tout sauf les caractères entre <code>a</code> et <code>z</code>	<code>[^0-9]</code> exclut les chiffres.
<code>[a-zA-Z0-9]</code>	Alphanumérique (lettres et chiffres)	<code>[a-zA-Z]</code> pour lettres.
<code>\sp</code>	Correspond au caractère spécial <code>sp</code>	<code>\.</code> correspond au caractère <code>.</code>

4. Construction des ER

Concaténation

- **Définition :** La juxtaposition de motifs sans opérateur.
 - **Exemples :**
 - `[A-Z][0-9]` : Une majuscule suivie d'un chiffre.
 - `abc` : Les caractères "abc" dans cet ordre.
-

Quantification

- **Définition :** Permet de définir combien de fois un motif doit apparaître.

Quantifieur	Signification	Exemple
<code>*</code>	0 ou plusieurs répétitions	<code>A*</code> correspond à "", "A", "AAA".
<code>+</code>	1 ou plusieurs répétitions	<code>A+</code> correspond à "A", "AAA".
<code>?</code>	0 ou 1 répétition	<code>A?</code> correspond à "", "A".
<code>{n}</code>	Exactement <code>n</code> répétitions	<code>A{3}</code> correspond à "AAA".
<code>{n,m}</code>	Entre <code>n</code> et <code>m</code> répétitions	<code>A{1,3}</code> correspond à "A", "AA".

Ancrage

- **Définition :** Fixe l'emplacement d'un motif dans une ligne.
 - **Symboles :**
 - `^` : Début de ligne.
 - `$` : Fin de ligne.
 - **Exemples :**
 - `^Linux` : Les lignes commençant par "Linux".
 - `Linux$` : Les lignes terminant par "Linux".
 - `^$` : Les lignes vides.
-

5. Combinaisons des ER

L'alternative (|)

- **Définition :** Correspond à "Ceci OU Cela".
- **Exemples :**
 - `Linux|Unix` : Le mot "Linux" ou "Unix".
 - `^[A-Z]|[0-9]{3}$` : Commence par une majuscule OU finit par trois chiffres.

Groupeage (())

- **Définition :** Permet de regrouper des motifs et d'appliquer des quantifieurs sur tout le groupe.
 - **Exemples :**
 - `(abc){2}` : "abcabc".
 - `(Linux|Unix)+` : Une ou plusieurs occurrences de "Linux" ou "Unix".
-

6. Classes et caractères spéciaux

Caractères spéciaux échappés

Caractère	Signification
<code>\n</code>	Nouvelle ligne
<code>\t</code>	Tabulation
<code>\103</code>	Code ASCII octal 103

Classes prédéfinies

Classe	Signification	Exemple
<code>[[:alpha:]]</code>	Lettres (majuscules et minuscules)	<code>[[:alpha:]]</code> : "a", "B".
<code>[[:digit:]]</code>	Chiffres	<code>[[:digit:]]</code> : "1", "9".
<code>[[:lower:]]</code>	Lettres minuscules	<code>[[:lower:]]</code> : "a", "z".
<code>[[:upper:]]</code>	Lettres majuscules	<code>[[:upper:]]</code> : "A", "Z".
<code>[[:space:]]</code>	Espaces	<code>[[:space:]]</code> : " ", <code>\t</code> .

7. Exemple détaillé : Recherche Prénom-Nom

Objectif

- Trouver des prénoms suivis de noms dans un texte.

Décomposition

1. **Prénom :** `[[[:upper:]][:lower:]]+`
 - Une majuscule suivie de lettres minuscules.
2. **Nom :** `[[[:upper:]]{2,}`
 - Deux lettres majuscules ou plus.
3. **Séparation :** `(^|[[[:space:]]])` et `[[[:space:]][:punct:]]|`\$)
 - Début/fin de ligne ou espace/ponctuation.

Expression complète

```
grep -E '(^|[[[:space:]]])[[[:upper:]][:lower:]]+  
[[[:upper:]]{2,}([[:space:]][:punct:]]|)$' fichier.txt
```

Exemples pratiques

Texte :

Rayan MIRI, Hicham AMMARI, Meryem CHAKIR.

Résultat :

- Correspond à : Rayan MIRI, Hicham AMMARI, Meryem CHAKIR.

8. Commandes Pratiques

grep

- **Description :** Recherche de motifs dans un fichier.
- **Syntaxe :**
- `grep 'motif' fichier`
- **Exemples :**
 - `grep '^Linux' fichier.txt` : Lignes commençant par "Linux".
 - `grep '[0-9]' fichier.txt` : Lignes contenant des chiffres.

sed

- **Description :** Modification des fichiers en ligne.
- **Syntaxe :**
- `sed -n '/motif/p' fichier`
- **Exemple :**
 - Supprimer les lignes vides :
 - `sed '/^$/d' fichier.txt`

awk

- **Description :** Extraction et transformation de données.
- **Syntaxe :**
- `awk '/motif/' fichier`
- **Exemple :**
 - Trouver les lignes contenant "Linux" :

- o `awk '/Linux/' fichier.txt`
