

• Chapitre 0 : Généralités

- Statistique descriptive : l'étude de la totalité de la population.
- Statistique inferentielle : l'étude d'une partie de la population et puis généraliser.

↳ Les avantages :

- ✓ Optimiser le coût et les ressources (humains, matériels).
- ✓ Prédire dans le cas d'absence de toute la population.
- ✓ Nécessité d'échantillonnage (vérifier la qualité des aliments).

* Définitions :

- la population : les éléments à étudier, un ciste fini noté Ω .
- Unité statistique : les éléments de Ω noté w .
- Caractère statistique : C , X ou Y est un trait présent chez les éléments de Ω d'une manière :
 - ↳ **exhaustive** : le caractère doit être présent chez tout les éléments de la population.
 - ↳ **incompatible** : un élément doit avoir une valeur / modalité unique.
- Modalités : les différentes valeurs de C .
- Observation : les modalités avec répétition.

• **exemple** : étude des poids des étudiants d'une classe.

- population : les étudiants
- caractère : le poids
- modalité : valeur possible du caractère.

modalité $\rightarrow x_i$	effectif n_i	f_i ou fréquence relative
N	$\sum f_i = 1$	$f_i = \frac{n_i}{N} \%$

o Preuve :

soit l'application $f : E \rightarrow F$
 \downarrow ensemble des étudiants \downarrow ensemble des poids.

\rightarrow si le caractère est exhaustif & incompatible alors f est définie.


exhaustif : $E = \cup A_i$

incompatible : $A_i \cap A_j = \emptyset$
 loi de probabilité.

\Rightarrow la distribution statistique peut être

- Application.
- Partition de la population

* Typologie du caractère :



• Chapitre 1 : statistique descriptive univariée :

C'est la donnée d'une description statistique avec une seule variable ou caractère statistique à étudier.

• exemple : Poids = f^{th} (Taille, Age, Sexe, Région).
 variable à expliquer variable explicative

\Rightarrow on cherche les variables explicatives qui interviennent et affectent plus la variable à expliquer.

① Représentation graphique :

• Caractère qualificatif :

On utilise principalement 3 types de représentation graphique :

le diagramme en bâtons, tuyaux d'orgue et par secteurs.

Lorsque le caractère étudié est la répartition géographique d'une population, la représentation graphique est un cartogramme.


↳ Diagramme en bâtons :



- Nous portons en abscisse les modalités, de façon arbitraire.
- Nous portons en ordonnée des segments dont la longueur est proportionnelle aux effectifs (ou aux fréquences) de chaque modalité.
- Nous appelons polygone statistique, ou diagramme polygonal, la ligne obtenue en joignant les sommets des bâtons.

↳ Tuyaux d'orgue :

- Nous portons en abscisses les modalités, de façon arbitraire.
- Nous portons en ordonnées des rectangles dont la longueur est proportionnelle aux effectifs, ou aux fréquences.



↳ Secteurs :

- Ces diagrammes conviennent très bien pour des données politiques ou socio-économiques.

- Caractère quantitatif:

Il existe deux types de représentation graphique:

- ✓ Différentiel: correspond à une représentation des effectifs ou des fréquences.

- ✓ Intégral: correspond à une représentation des effectifs cumulés, ou des fréquences cumulées.

↳ Variable statistique discrète:

- ✓ Diagramme en bâtons, la différence avec le cas qualitatif consiste en ce que les abscisses ici sont des valeurs de la variable statistique.

- ✓✓ Courbe en escaliers des effectifs cumulés ou des fréquences

↳ Variable statistique continue:

les observations sont regroupées en classes, chaque classe possède une certaine amplitude, qui est la longueur de I définissant la classe.

- Densité d'effectif: le rapport entre n_i et son amplitude.

- Densité de fréquence: le rapport entre f_i et son amplitude.

- ✓ Histogramme des densités: en abscisse les classes représentant les modalités et en ordonnées des rectangles dont la longueur est proportionnelle à la densité d'effectif ou de fréquence.

- ✓✓ Courbe cumulative des effectifs ou des moyennes


② Paramètres statistiques: qui caractérisent la distribution

↳ de position: (entre un max et min).

- les paramètres qui permettent de savoir autour de quelles valeurs se situent les valeurs d'une variable statistique.


* mode: modalité qui a la plus grande fréquence.

→ si une distribution est multimodal, donc la population est hétérogène.



la note

* la classe modale: pour une variable quantitative continue.



$$\frac{M_0 - x_i}{\Delta 1} = \frac{x_{i+1} - M_0}{\Delta 2}$$

$$M_0 = x_i + \frac{\Delta 1}{\Delta 1 + \Delta 2} (x_{i+1} - x_i)$$

* la médiane: m_e c'est une modalité qui va diviser la population en deux parties:


1^{ère} partie: modalité < médiane

2^{ème} partie: modalité > médiane

} de même taille
 $n = 14$

Elle est défini: si la description est quantitative, si la relation d'ordre existe \Rightarrow quantitative ordinal.

Si N est impaire:



* la moyenne : définie quand la distribution est quantitative.

$$\bar{X} = \frac{1}{N} \sum \overset{\text{modalité}}{X}(w) = \frac{1}{N} \sum n_i x_i = \sum f_i x_i$$

⇒ propriétés de la moyenne :

• Somme : X et Y 2 distri^s stat quantitativ^s sur Ω alors $X+Y$ est une distri^s stat sur Ω

$$X : \Omega \longrightarrow \mathbb{R}$$

$$Y : \Omega \longrightarrow \mathbb{R}$$

$$X+Y : \Omega \longrightarrow \mathbb{R}$$

$$\textcircled{1} w \longrightarrow (X+Y)(w) = X(w) + Y(w)$$

$$\textcircled{2} \overline{X+Y} = \bar{X} + \bar{Y}$$

• Produit par un scalaire : $\overline{\lambda X} = \lambda \bar{X}$

• Ecart moyen à la moyenne : $\overline{X - \bar{X}} = 0 \quad (\bar{\bar{X}} = \bar{X})$

* la moyenne conditionnée : si on divise la population à des sous populations, chaque sous population est triée à l'aide d'une condition (région, niveau, ...). La moyenne de chaque sous population est une moyenne conditionnée. et la moyenne de tous les moyennes conditionnées est la moyenne (générale).

• la moyenne c'est la moyenne des moyennes conditionnées pondérées par la taille des parties. $\bar{X}^i = \frac{1}{n_i} \sum n_{ij} x_{ij}$

* la moyenne d'une variable continue :

x_i	n_i
[7
[30
[10

$$\bar{X} = \frac{1}{N} \sum_{i=1}^p n_i \bar{X}^i \text{ avec } \bar{X}^i \text{ la marge à l'intérieur de } [x_i, x_{i+1}]$$

Selon l'hypothèse 1: Dans chaque classe, toutes les observations sont concentrées au centre de la classe.

et l'hypothèse 2: la répartition des observations est uniforme.

$$\bar{x}^i = \frac{x_i + x_{i+1}}{2}$$

* Généralisation de la notion de moyenne:

↳ la φ -moyenne:

Soit X une variable stat réelle sur Ω : $\varphi: \mathbb{R} \rightarrow \mathbb{R}$
application localement inversible

on peut calculer la moyenne de φ : $\bar{\varphi}(X) = \frac{1}{N} \sum n_i \varphi(x_i)$

$\varphi \circ X: \Omega \longrightarrow \mathbb{R}$ est une distib stat réelle sur Ω

$$\bar{X}^\varphi = \varphi^{-1}(\overline{\varphi \circ X}) \Rightarrow \text{la } \varphi \text{ moyenne de } X.$$

• exemple

1/ la moyenne arithmétique: $\varphi: X \longrightarrow X$ app identique

$$\bar{X}^\varphi = \text{Id}^{-1} \left(\frac{1}{N} \sum n_i \text{Id}(x_i) \right) = \bar{X}$$

2/ la moyenne quadratique: $\varphi: X \longrightarrow X^2$

$$\bar{X}^\varphi = \sqrt{\frac{1}{N} \sum n_i x_i^2} = \bar{X}_q$$

3/ la moyenne harmonique: $\varphi: X \longrightarrow 1/X$

$$\bar{X}^\varphi = \left(\frac{1}{N} \sum \frac{n_i}{x_i} \right)^{-1} = \bar{X}_h$$

4) la moyenne géométrique: $\varphi: X \rightarrow \ln(X)$

$$\bar{X}^{\varphi} = \exp\left(\frac{1}{N} \sum n_i \ln(x_i)\right) \\ = \sqrt[n]{\prod_{i=1}^p x_i^{n_i}} = \bar{X}_g$$

* Propriétés de la φ -moyenne:

$$\bar{X}_R \leq \bar{X}_g \leq \bar{X} \leq \bar{X}_q$$

- Il y a égalité ssi toutes les valeurs de X sont égales.
- \bar{X}_g est bien adaptée à l'étude des phénomènes de croissance.
- \bar{X}_g est utilisée pour les calculs d'indices économiques.


↳ De dispersion:

* étendue: $w = x_{\max} - x_{\min}$

* Quartile: généralisation de la médiane.


• variable statistique continue:

on appelle quartiles les nombres Q_1 , Q_2 et Q_3 pour lesquels les f cumulées de X sont respectivement 0,25; 0,50; 0,75.




- les quartiles partagent l'étendue en 4 I qui ont le même effectif.
- le Q_2 est égal à la médiane.
- L'intervalle interquartile est la différence entre Q_3 et Q_1 , il contient 50% des valeurs de X .

• variable statistique discrète:



les quartiles seront déterminés par interpolation linéaire entre deux valeurs.



- * **percentiles**: diviser I en 100 I_i de même effectif.
- * **déciles**: partager l'étendue en 10 de même effectif.
- * **Ecart absolu moyen**: $e = \frac{1}{N} \sum n_i |x_i - \bar{x}|$, difficile à manipuler
- * **Variance**: la dispersion autour de \bar{x}

$$V(X) = \overset{\text{notation}}{s^2(X)} = \frac{1}{N} \sum n_i (x_i - \bar{x})^2$$

$$\Rightarrow \text{l'écart type: } s(X) = \sqrt{\frac{1}{N} \sum n_i (x_i - \bar{x})^2}$$

$$\Rightarrow \text{formule de la variance } \overset{\text{König}}{\text{König}}: \text{la moyenne des carrés} - \text{le carré de la moyenne: } V(X) = s^2(X) = \overline{x^2} - \bar{x}^2$$

\Rightarrow propriété de la variance:

- $V(X) \geq 0 \quad \forall X$
- $V(X) = 0$ ssi X est cste.
- $s^2(ax+b) = a^2 s^2(X)$


\Rightarrow **Inertie**: C'est une généralisation de la variance, la moyenne des carrés des écarts à une référence a .

$$I_a(X) = \frac{1}{N} \sum n_i (x_i - a)^2$$

$$I_a(X) = s^2(X) + (a - \bar{x})^2$$

* **Variance conditionnée**:

X la distribution stat si : $\Omega = \cup x_j$



$$\bar{x} = f(\bar{x}_j) ?$$

$$\bar{x} = \frac{1}{N} \sum n_j \bar{x}_j$$

→ Chaque partie à une moyenne conditionnée et variance conditionnée, pour la moyenne \bar{x} c'est la moyenne des moyennes conditionnées pondérée par l'effectif, Est-ce que c'est le cas de la variance?

$$\bullet \sigma^2(x) = f(\sigma_j^2(x), \bar{x}_j)$$

$$\sigma^2(x) = \frac{1}{N} \sum n_j \sigma_j^2(x) + \frac{1}{N} \sum n_j (\bar{x}_j - \bar{x})^2$$

$\sigma_w^2(x)$
variance intraclass
(dispersion / à l'intérieur de \bar{x})

$\sigma_b^2(x)$
variance interclass (dispersion entre les classes)

⇒ c'est la moyenne des variances conditionnées + la variance des moyennes conditionnées.

• **Classification** : quand X dépend de y mais X n'est pas numérique. $f(E, t) \xrightarrow{G} F$

• **Corrélation** : Lorsqu'une variable stat dépend d'une condition.

↳ Coefficient de corrélation de X en $(\cup R_j)$:

$$\text{pas de corrélation} \rightarrow 0 \leq R^2 = \frac{\sigma_b^2(x)}{\sigma^2(x)} \leq 1 \rightarrow \text{forte corrélation}$$

$$\bullet \text{ si } R = 1 \Rightarrow \sigma_w^2(x) = 0 \Rightarrow \sigma_j^2(x) = 0 \rightarrow x_j \text{ est ct}$$

exemple : toute la population d'une classe a 18 en note → corrélation

* si $\rho = 0 \Rightarrow \sigma_b^2(x) = 0$



exemple: toutes les classes ont une moyenne = 18, x ne dépend pas de la classe.

• Remarques: p 26 x et y deux variables stat sur Ω

x une variable stat
 y une partition $\left\{ \Rightarrow R_{x/y} = \frac{\sigma_b^2(x)}{\sigma^2(x)} \right.$ dépend de x et y
car σ_b^2 c'est la variance des moyennes conditionnées

y une variable stat
 x une partition $\left\{ \Rightarrow R_{y/x} = \frac{\sigma_b^2(y)}{\sigma^2(y)} \right.$

* si x dépend de y cela n'implique pas y dépend de x



• $\sigma^2(x) = \frac{1}{N} \sum n_i \sigma_i^2(x) + \frac{1}{N} \sum n_i (\bar{x}_i - \bar{x})^2$

↳ selon type 1: $\sigma_i^2(x) = 0$ pas de dispersion.

$\sigma^2(x) = \sigma_b^2(x)$

↳ selon type 2: $\sigma_i^2(x) = \frac{(x_{i+1} - x_i)^2}{12}$

$\sigma_i^2(x) = \frac{12}{x_{j+1}^2 - x_j^2}$

* Moments:

↳ moment d'ordre r : $m_r = \frac{1}{N} \sum [X(w)]^r = \frac{1}{N} \sum n_i x_i^r$
c'est la $(\bar{x})^r$

- si $r=0$: $m_0 = 1$

- si $r=1$: $m_1 = \bar{X}$

- si $r=2$: $m_2 = \bar{X}^2$

↳ moment centré d'ordre r : $\mu_r = \frac{1}{N} \sum (X(\omega) - \bar{X})^r = \frac{1}{N} \sum n_i (x_i - \bar{X})^r$

- si $r=0$: $\mu_0 = 1$

- si $r=1$: $\mu_1 = 0$

- si $r=2$: $\mu_2 = S^2(X) = m_2 - m_1^2$, le moment centré d'ordre 2 c'est la variance.

- Distribution statistique centrée: $\bar{X} = 0$

Soit X une distribution statistique réelle sur Ω alors $X - \bar{X}$ est une distribution stat réelle sur Ω nommée la dist stat associée à X .

- Exemple: le poids des étudiants $\bar{P} = 50 \text{ kg}$

$$P - \bar{P} = (\text{pour } P = 50 \text{ kg}) \quad 0$$

$$P = 48 \rightsquigarrow -2 \text{ devient le nouveau poids dans cette dist}$$

$$P = 52 \rightsquigarrow 2 \quad " \quad " \quad " \quad "$$

- Distribution centrée réduite.

$$\frac{X - \bar{X}}{\sigma(X)} \quad \text{avec : } \bar{X} = 0 \quad \text{et} \quad \sigma(X) = 1$$


$$V(aX+b) = a^2 V(X) \quad V\left(\frac{X - \bar{X}}{\sigma(X)}\right) = \frac{1}{\sigma^2(X)} V(X) = 1$$

↳ Apr


⇒ prq centrer et réduire une distribution?

pour qu'on puisse la comparer à une référence.

• Exemple:



loi normal



si je souhaite comparer cette distn à la loi normal, on doit la redimensionner.

↳ De faire:

* Coefficient d'asymétrie:

① Pearson: intervenir le mode

$$P = \frac{\bar{X} - M_0}{s(X)}$$

← le mode
← l'écart type



② Yule: intervenir la médiane et les quartiles

$$Y = \frac{Q_1 + Q_3 - 2M_e}{2(Q_3 - Q_1)}$$



③ Fisher: intervenir les moments centrés

$$F = \frac{\mu_3}{\mu_2^{3/2}} = \frac{\mu_3}{s^3(X)}$$

• Si le coefficient > 0 : on dit qu'il y a obliquité à gauche.



• Si le coefficient < 0 : on dit qu'il y a obliquité à droite.



• Pearson basé sur les moments centrés:

nous donne la précision $\leftarrow \beta_1 = \frac{\mu_3^2}{\mu_2^3}$

→ très positif
→ nul pour une dist à densité de fréquence symétrique, telle que la loi de Gauss

* Coefficient d'aplatissement:

① Pearson: $\beta_2 = \frac{\mu_4}{\mu_2^2}$

② Yule: $F_2 = \frac{\mu_4}{\mu_2^2} - 3$